



Webcrawler Dashboard

Projektarbeit im Rahmen meines Bachelor of Science (B. Sc.) Studiums in Medieninformatik im Fachbereich Umweltplanung/Umwelttechnik am Umwelt-Campus Birkenfeld.

Vorgelegt von: Yasmine Weiwert

Erstprüfer: Prof. Dr. Rolf Krieger

Abgabetermin: 13.09.2024

Kurzbeschreibung:

Es gibt ein bestehendes Projekt eines Webcrawlers, der Produktdaten aus Online-Shops extrahiert und in einer Datenbank speichert. Das Ziel dieses technischen Projekts ist es, an diese Datenbank anzuknüpfen und eine einfache visuelle Hilfe zur Anzeige der Daten bereitzustellen.

Die Idee ist, mit Hilfe von Streamlit ein Dashboard zu entwickeln. Dieses soll mit der Datenbank von Mongodb verbunden werden und die Daten visuell ansprechend darstellen.

Table of Contents

Einleitung	3
Motivation	3
Problemstellung	3
Technische Grundlagen	3
MongoDB	3
Verbindung zur Mongodb in Streamlit	3
Streamlit	4
Schritte der Installation:	4
User Interface Design	6
Aufbau und Funktionalität der einzelnen Seiten	6
Startseite:	7
Suche	7
Completeness Allgemein	8
Completeness GTIN	9
Completeness Nährwerttabelle	9
Completeness Preise	10
Completeness Allgemein je Shop	10
Completeness GTIN je Shop	11
Completeness Nährwerttabelle je Shop	12
Completeness Preise je Shop	13
Implementierung	14
Probleme	14
Flatten	15
Was bedeutet flatten?	15
Vergleich der Daten mit und ohne Flatten	15

Einleitung

Motivation

Die Motivation war, eine Visualisierung einer Datenbank zu erstellen, die auch später noch gut genutzt werden kann.

Problemstellung

Im Vorfeld gab es eine Datenbank und es sollte eine Visualisierung der Daten entwickelt werden und es sollte eine Möglichkeit geben, einfach darauf zuzugreifen. Dann wurde Streamlit als Framework vorgestellt und es sollte damit gearbeitet werden, um das Ziel zu erreichen, ein Dashboard für einen Webcrawler zu entwickeln.

Technische Grundlagen

MongoDB

Mongodb ist eine Datenbank, die in diesem Projekt die Daten der einzelnen Shops speichert. Mit dem Dashboard kann dann darauf zugegriffen werden mit einem einfacheren Interface und ohne die gesamte Datenbank öffnen zu müssen.

Verbindung zur Mongodb in Streamlit

Zur Verbindung mit dem Mongo-Client wurde eine Funktion wie folgt geschrieben:

```
@st.cache_resource
def init_connection():
    connection_string = st.secrets["mongo"]["connection_string"]
    return pymongo.MongoClient(connection_string)

client = init_connection()
```

Wobei der "connection_string" auch sofort eingefügt werden kann. Es gibt eine secrets.toml Datei welche Informationen speichert die nicht jeder über Github bekommen soll. Dies wird notwendig, wenn man über die Mongodb Cloud sich mit der Datenbank verbindet. Der sogenannte "connection_string" benutzt bei der Verbindung über Cloud einen String mit Benutzernamen und Passwort.

In unserem Fall verbinden wird uns lokal mit der Datenbank und dies sieht dann so aus:

"mongodb://localhost:27017/"

Dieser String ist in der secrets.toml gespeichert.

Ohne die secrets.toml würde es so aussehen:

```
@st.cache_resource
def init_connection():
    connection_string = "mongodb://localhost:27017/"
    return pymongo.MongoClient(connection_string)

client = init_connection()
```

Es funktioniert auch noch kürzer mit:

```
@st.cache_resource
def init_connection():
    return pymongo.MongoClient("mongodb://localhost:27017/")
client = init_connection()
```

Es werden keine Variablen verwendet und es wird direkt in die MongoClient() Funktion geschrieben.

Streamlit

Streamlit ist ein Open-Source-Python-Framework zur Visualisierung von Daten in Web-Apps. In Python wird das Backend-Script geschrieben und mit dem Streamlit-Paket stehen Funktionen zur Verfügung, die das Programmieren einer Web-Applikation vereinfachen.

Es gibt die Möglichkeit streamlit über die Kommandozeile oder mit Anaconda zu installieren. Bei der Kommandozeile muss Python auf dem System installiert sein und es muss mehr Code geschrieben werden. Anaconda bietet eine grafische Hilfe, um ein Streamlit-Projekt ohne Python-Installation zu entwickeln.

Bei diesem Projekt wurde eine Installation über die Kommandozeile benutzt.

Dafür benötigt man für Windows:

- Python Version 3.8 3.12
 - o Dies kann auf der Webseite installiert werden auf "www.python.org"
- Manager f
 ür die Python Umgebung (virtuelle Umgebung)
 - o In diesem Projekt wurde hierfür venv benutzt
- Python Package Manager
- Code Editor
 - o Als Code Editor wurde für dieses Projekt Visual Studio Code benutzt.

Schritte der Installation:

1. In das Projekt navigieren. Entweder über die Kommandozeile mit "cd Webcrawlerprojet" in das Projekt navigieren oder im VS-Code mit der rechten Maustaste auf den entsprechenden Ordner klicken und "Open in Integrated Terminal" wählen.

- 2. Dann im Terminal "python -m venv .venv" ausführen. Dies bringt ein neuen Ordner mit dem Namen "venv" in das Projekt. Dies ist die virtuelle Umgebung die für streamlit benutzt wird.
- 3. In der Powershell kann dann die virtuelle Umgebung aktiviert werden mit dem Commando: ".venv\Scripts\Activate.ps1" Dies ist aktiviert wenn am Anfang der Zeile in der Kommandozeile "(.venv)" in grün angezeigt wird.
- 4. Nun mit virtueller Umgebung aktiv: "pip install streamlit" benutzen, dies installiert alles rund um streamlit das benötigt wird
- 5. Um es zu testen, kann man ein Test-Script aufrufen mit "streamlit hello" oder "streamlit -m hello"

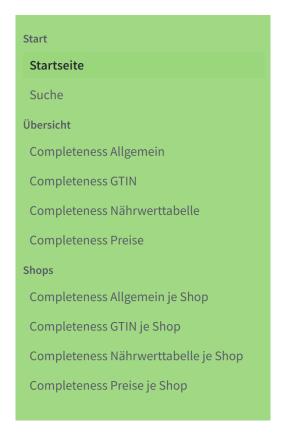
Von hier an kann man neue Python Scripte anlegen und die direkt aufrufen. Als Beispiel haben wir eine Startseite.py und die kann nun mit "streamlit Startseite.py" direkt aufgerufen werden.

In diesem Projekt rufen wir "streamlit_app.py" auf. Diese Seite ist eine Setup Seite, die genau sagt, welche Seiten aufgerufen werden und weitere Einstellungen. In dem Abschnitt zu "Aufbau und Funktionalität" der einzelnen Seiten wird dies genauer erklärt.

User Interface Design

Aufbau und Funktionalität der einzelnen Seiten

Dies sind alle Seiten des Dashboardes:



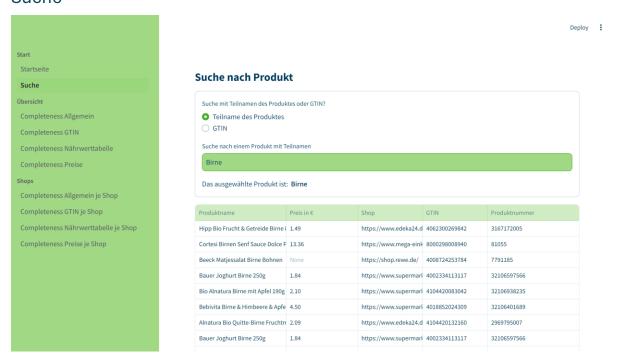
Diese werden in der Webanwendung auf der linken Seite wie in folgendem Beispiel angezeigt.

Startseite:



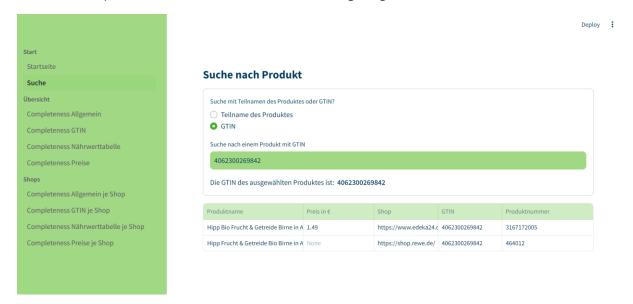
Auf diesem Bild wird die Startseite gezeigt. Diese zeigt eine generelle Übersicht aller Shops die vom Webcrawler zugegriffen werden, deren Anzahl an Produkten und die "Completeness" aller Shops. Die "Completeness" ist die Vollständigkeit der Daten die aus den jeweiligen Shops herausgelesen werden.

Suche



Auf der Suchseite kann man nach Produkten suchen. Die erste Möglichkeit nach einem Produkt zu suchen ist den Namen des Produktes einzugeben. Es genügt einen Teil des Namens einzugeben. Als Beispiel, wenn Birne eingetippt wird, dann werden alle Produkte, die das Wort

Birne beinhalten angezeigt. Es werden zu dem gesuchten Produkt dann jeweils der Name, der Preis, der Shop, die GTIN und die Produktnummer angezeigt.



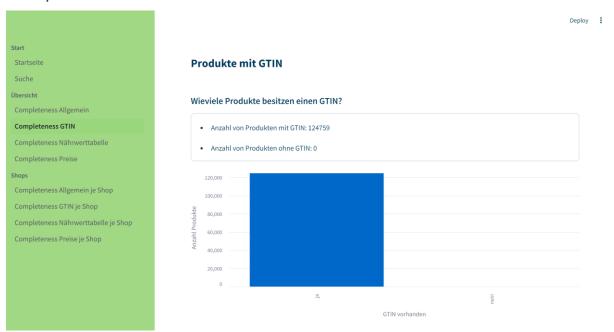
Die zweite Möglichkeit ist ein Produkt mit seiner GTIN zu suchen. Dies zeigt dann nur das Produkt mit der jeweiligen GTIN an. Dies kann auch in mehreren Shops verfügbar sein, aber hat je Shop einen anderen Produktnamen.

Completeness Allgemein



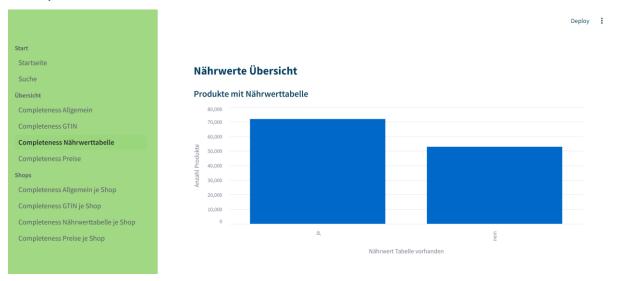
Die "Completeness Allgemein" Seite zeigt eine Übersicht wieviele Produkte in welchem Completeness Bereich liegen. Zudem zeigt es die Quartile wie auch Median der Completeness Werte an.

Completeness GTIN



Die "Completeness GTIN" Seite zeigt an wieviele Produkte aller Produkte insgesamt eine GTIN besitzen und wieviele keine GTIN besitzen.

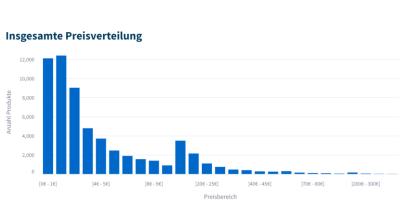
Completeness Nährwerttabelle



Die "Completeness Nährwerttabelle" Seite zeigt eine Übersicht der Produkte mit Nährwerttabelle und die Produkte ohne Nährwerttabelle. Es kann man genauso rauslesen welche Produkte Lebensmittel sind und welche mit hoher Wahrscheinlichkeit nicht.

Completeness Preise





Die "Completeness Preise" Seite zeigt wieviele Produkte in einem bestimmten Preisbereich liegen. Da sehr viele Produkte zu den niedrigeren Preisklassen gehören, sind die ersten Bereiche jeweils kleiner. Von 0€ bis 10€ sind es jeweils Schritte je 1€. Von 10€ bis 50€ sind es jeweils 5€ Schritte. Von 50€ bis 100€ sind es jeweils 10€ Schritte und danach bis 500€ sind es 100€ Schritte. Da es in den höheren Preisbereichen weniger Produkte verkauft werden, sind die Bereiche grösser, da dies sinnvoller darzustellen ist.

Completeness Allgemein je Shop



Completeness-Bereich je Shop Durschnittliche Completeness		
Shop	Completeness	
https://www.globus.de/	0.75	
https://www.supermarkt24h.de/	0.68	
https://www.edeka24.de/	0.7	
https://www.volgshop.ch/	0.63	
https://shop.rewe.de/	0.61	
https://www.heinemann-shop.com/	0.76	
https://www.mega-einkaufsparadies.de/	0.76	
	0.56	

Die "Completeness Allgemein je Shop" Seite zeigt pro Shop den Durschnitt der Vollständigkeit der Daten der Produkte an. Auch als Durschnittliche Completeness zu verstehen.

Deploy :

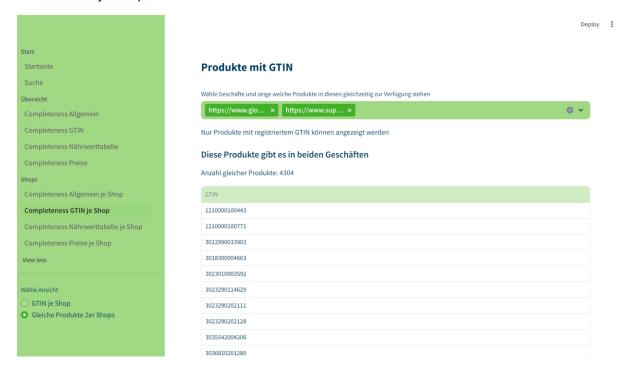
Deploy :

Completeness GTIN je Shop



Auf dieser Seite wird die Anzahl der Produkte mit GTIN angezeigt je Shop. Zudem wird angezeigt zu wieviel Prozent die GTIN tatsächlich vorhanden ist. Wenn also eine GTIN nicht vorhanden sein sollte, wird dies mit dieser Tabelle sofort sichtbar.

Unten links gibt es die Auswahl der Ansichten zu dieser Seite. Die erste Ansicht ist diese Tabelle mit der GTIN je Shop.

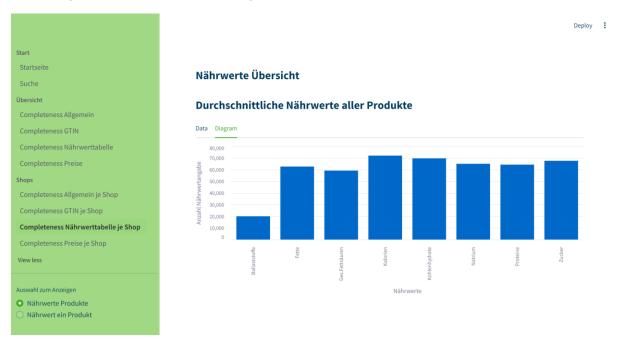


Bei der Auswahl zur Ansicht "Gleiche Produkte 2er Shops" können zwei Shops ausgewählt werden und in der Tabelle werden dann alle GTINs aufgelistet mit Produkten, die in beiden Shops erhältlich sind.

Completeness Nährwerttabelle je Shop



Diese Seite zeigt die Anzahl der Produkte, die es je Nährwerte gibt. Dies einmal in einer Auflistung, als auch in Form eines Diagrammes.

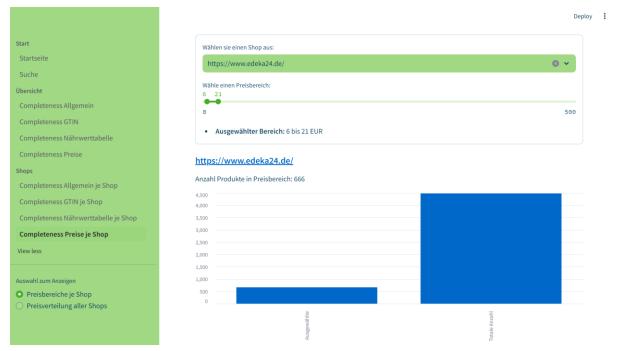


Die Diagramme zeigen in der Form eines Balkendiagrammes die gleiche Information wie "Data".



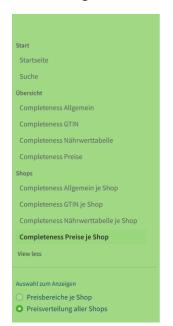
Es gibt zweit Ansichten zu dieser Seite. Eine davon zeigt die generelle Übersicht aller Nährwerte und der Anzahl der Produkte. Eine zweite Ansicht zeigt die Nährwerte eines Produktes. Das bedeutet, dass man einen Suchbegriff eingeben kann und man die Nährwerte der Suchergebnisse bekommt. Jedes gefundene Produkt wird somit mit den Nährwerten aufgelistet. Nur jene ohne Nährwerttabelle werden nicht aufgelistet.

Completeness Preise je Shop



Diese Seite hat zwei Ansichten. Die erste Ansicht zeigt die Anzahl Produkte eines Shops in einem bestimmten Preisbereich. Der Nutzer kann einen Shop und einen Preisbereich

auswählen. Danach wird dann mit Hilfe eines Balkendiagrammes angezeigt, wie viele Produkte in dem ausgewählten Abschnitt zu finden sind. Es zeigt zudem die gesamte Anzahl.



Anzahl Produkte in einer spezifischen Preisgruppe

Shop	Preisdurchschnitt
https://www.globus.de/	3.21
https://www.supermarkt24h.de/	6.07
https://www.edeka24.de/	6.78
https://www.volgshop.ch/	5.3
https://shop.rewe.de/	0
https://www.heinemann-shop.com/	58.09
https://www.mega-einkaufsparadies.de/	12.55
https://www.lidl.de/	16.49

Die zweite Ansicht zeigt den Durschnitt der Preise aller Shops.

Implementierung

Probleme

Die meisten Probleme bei der Entwicklung des Dashboards gab es bei den Laufzeiten. Anfangs waren die Laufzeiten sehr langsam. Da war die Datenbank über eine Cloud erreichbar und der Weg die Daten abzugreifen war länger. Danach sind die Daten lokal vom Rechner abgerufen worden und dies ging schon ein gutes Stück schneller.

Danach ging es trotzdem noch generell zu langsam mit dem Laden. Da wurde eine sauberer Implementierung gefunden die nicht immer die Funktion get_data() aufruft. Diese Funktion sucht die Daten aus der Datenbank und speichert diese in einer Liste.

Um es dann wieder schneller zu gestalten wurde die Anfrage zur Datenbank eingeschränkt mit der find Funktion. Dies hat geholfen die Datenmenge zu reduzieren und somit schneller ein Ergebnis aufrufen zu können.

Die Finale Lösung um die Laufzeit nochmals zu verbessern war die Daten anders zu verarbeiten. Dieser Prozess heißt Flatten. In dem nächsten Abschnitt wird mehr zu flatten und den Ladezeiten erklärt.

Flatten

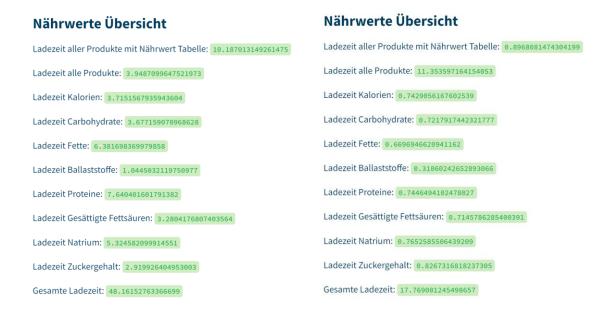
Was bedeutet flatten?

Bei der Collection, die wir ursprünglich benutzt haben werden Daten in einer Hierarchie angeordnet und mit mehreren Spalten angezeigt. Flatten ist eine Funktion in Python die diese Hierarchie aufhebt und es Daten ohne Spalten, sondern nur noch Zeilen abspeichert. Alles wird in einer Liste angeordnet in dieser Collection. Die macht das Abrufen schneller.

Vergleich der Daten mit und ohne Flatten

Erster Test – Flatten nur der Nährwerttabelle:

Links ohne die Collection zu flatten und rechts mit Collection zu flatten:



Diese benutzt auch die Collection die geflattet wurde und benutzt nur eine get_data() Funktion:

Nährwerte Übersicht

Ladezeit aller Produkte mit Nährwert Tabelle: 0.698108434677124

Ladezeit alle Produkte: 4.39008092880249

Gesamte Ladezeit: 5.932839632034302

Fazit

Als Fazit kann man sehen, dass dieses Dashboard das Lesen der Daten ein Stück einfacher macht. Generell zum Programmieren mit Streamlit kann man auch sagen, dass es einfach ist sich einzuarbeiten und es viele Möglichkeiten gibt mit dem Framework eine Visualisierung der Daten zu ermöglichen. Mit großen Datenmengen jedoch kann die Ladezeit hier zu einem größeren Problem werden. Doch mit der richtigen Herangehensweise ist dies auch zu lösen.